

# Procesado de Información Biológica Sesión 7

Mónica Rojas Martínez



Universidad El Bosque



# Contenido

- › Regresión lineal
- › Modelo con múltiples entradas
- › Función de coste y algoritmo gradiente descendente



# Aprendizaje automático

- › Conjunto de métodos para predecir un evento o una salida a partir de un conjunto de ejemplos (entradas)
- › Si la variable de salida es continua se habla de una regresión. Ej: predecir el clima durante el día (18.5° a las 7.00 am, 22° a las 12m). Cuales pueden ser las entradas? Cuantas salidas hay? Cuales son dichas salidas y que valores toman?
- › Si la variable de salida es discreta se habla de una clasificación. Ej. En una población se quiere diferenciar entre deportistas (clase 1) y sedentarios (clase 0). Cuales pueden ser las entradas? Cuales y cuantas las salidas?



# Regresión lineal con una variable

Hasta ahora




|          | $x$      | $y$    |
|----------|----------|--------|
| $Obs^1$  | 0,8      | 74856  |
| $Obs^2$  | 1,8      | 76925  |
| $\vdots$ | $\vdots$ |        |
| $Obs^m$  | 10,8     | 278624 |

Hipótesis :  $h(x) = \theta_0 + \theta_1 x_1$

$$h(x) = \theta^T \mathbf{x}$$

Con  $\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \end{bmatrix}$ ,  $\mathbf{x} = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix}$  y  $x_0 = 1$ ,


Función de coste:  $J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h(x^i) - y^i)^2$





# Regresión lineal con múltiples variables

Ahora



Hipótesis :  $h(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$

Función de coste:  $J(\theta_0, \dots, \theta_n) = \frac{1}{2m} \sum_{i=1}^m (h(x^i) - y^i)^2$



# Hipótesis Regresión lineal con múltiples variables

$$\triangleright h(x) = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

Si Por conveniencia definimos  $x_0 := 1$

Podemos escribir las entradas y los parámetros de forma vectorial como:

$$\mathbf{x} = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} 1 \\ x_1 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^{n+1} \quad \text{y} \quad \boldsymbol{\theta} = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix} \in \mathbb{R}^{n+1}$$


$$\rightarrow h(x) = \boldsymbol{\theta}^T \mathbf{x}$$





# Regresión con múltiples variables (general)

Un modelo no lineal de múltiples variables considera por ejemplo:



$$h(x) = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

Con  $x_3 = x_1^2$ ,  $x_4 = x_2^2$ ,  $x_5 = x_1 x_2$

**Hipótesis (“no lineal”) :**  $h(x) = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 + \theta_5 x_1 x_2$

Función de coste:  $J(\theta_0, \dots, \theta_n) = \frac{1}{2m} \sum_{i=1}^m (h(x^i) - y^i)^2$



## Ajuste de parámetros

- › A partir del conjunto de datos de entrenamiento, encontrar los valores del vector  $\theta$
- › Con este propósito se utilizan métodos de optimización sobre una función convexa en sentido amplio ( es decir, con un único mínimo absoluto)
- › Métodos de optimización: muy variados, ejemplo → gradiente descendente





# Gradiente descendente (idea general)

